DATA ENGINEERING APPLICATIONS

NKDT Consulting Group

Diomande Aminata Sarah Fatim

Denis Solyane

Traoré Gnible Aminata

Kouton Danielle

Ce projet a pour objectif de centraliser, traiter et valoriser deux types de données essentielles pour l'entreprise Amoric Fried Chicken : les données de ventes (*Sales*) et les retours clients (*Feedback*). Ces informations, initialement disponibles sous forme de fichiers CSV déposés dans un espace Teams, doivent être transformées en un ensemble de données fiables, propres et facilement exploitables pour l'analyse et la prise de décision.

Pour atteindre cet objectif, nous avons choisi de construire l'ensemble du traitement dans l'écosystème Azure, en nous appuyant sur **Microsoft Fabric** pour l'ingestion, la transformation et le stockage des données, et sur **Power BI** pour la visualisation et l'analyse. Ce choix s'est imposé pour plusieurs raisons.

D'abord, Microsoft Fabric offre un environnement unifié qui regroupe toutes les briques nécessaires à un projet data : un espace de stockage centralisé (Lakehouse), des pipelines d'ingestion automatisés, des notebooks pour le traitement, et des tables Delta pour un stockage performant et fiable. Cette intégration évite la multiplication des outils et simplifie la gestion du projet. De plus, Fabric s'intègre naturellement avec Teams grâce aux *Shortcuts*, ce qui permet de récupérer les fichiers déposés par les équipes sans duplication ni manipulation complexe.

Ensuite, Power BI complète parfaitement cette architecture en permettant de connecter directement les tables Silver du Lakehouse pour créer des tableaux de bord dynamiques et interactifs. L'ensemble forme une chaîne cohérente : les données sont collectées, nettoyées, historisées puis visualisées dans un même écosystème, ce qui garantit une continuité technique et une grande facilité d'utilisation.

Ce rapport présente donc la démarche adoptée pour traiter les données Sales et Feedback, les choix techniques réalisés, ainsi que la structure de traitement mise en place pour assurer un flux de données automatisé, fiable et évolutif.

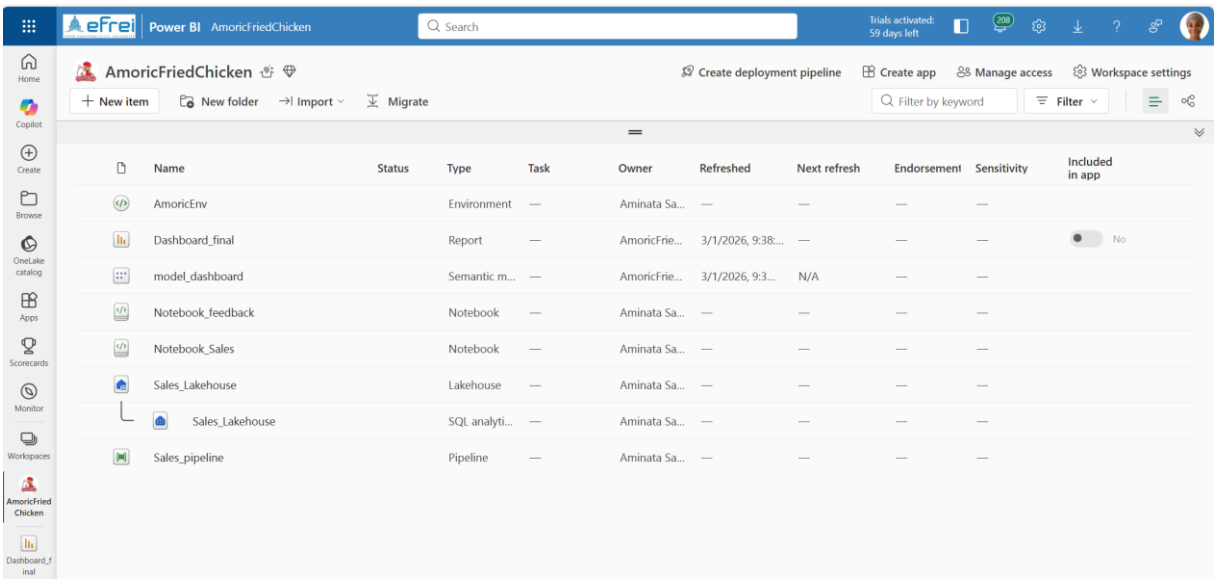

A- TRAITEMENT DES DONNEES DE VENTES

L'objectif du projet est de mettre en place une chaîne de traitement automatisée permettant d'ingérer, nettoyer, transformer et historiser des données de ventes provenant de fichiers CSV. L'enjeu principal est de garantir une ingestion fiable et automatisée et une base de données exploitable pour l'analyse et la visualisation.

A.1. Source des données : Raccourci vers Teams

Les fichiers CSV sont stockés dans un dossier Teams. Pour les utiliser dans Microsoft Fabric, nous créons un **Shortcut Fabric.** Ce raccourci permet à Fabric de "voir" les fichiers Teams sans les copier. Ce choix permet une synchronisation en temps réel entre le dossier Teams et Fabric. Ainsi, chaque fois que les les équipes déposent des fichiers dans le dossier, Fabric les récupère automatiquement.

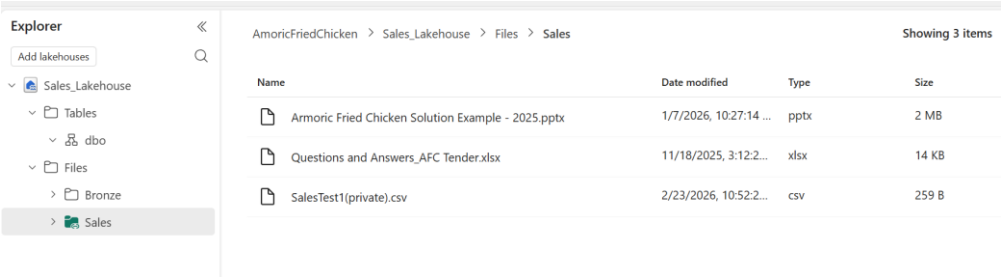

A.2. Organisation du traitement

Un pipeline est un petit programme automatisé qui s'exécute selon un planning. Ici, notre pipeline comporte deux activités principales qui séparent clairement l'ingestion brute et la transformation :

- **Copy Data** : copie les fichiers CSV depuis le Shortcut vers la couche *Bronze* du Lakehouse.
- **Notebook** : exécute un script PySpark pour transformer et nettoyer les données afin de les stocker dans les tables Delta dans la couche *Silver*

Cette architecture suit les standards modernes du data engineering, permettant de conserver les données brutes pour audit ou retraitement et de produire des tables propres, typées et dédupliquées pour la Business Analyse.

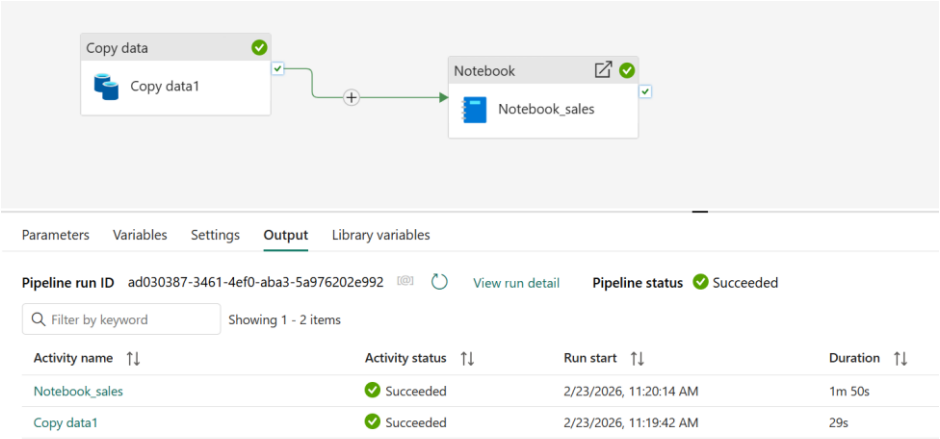

A.3 Traitement des données dans le Notebook

- **Création de la table de tracking :** D'abord une table *file_tracking* est créée contenant les informations sur les fichiers csv traités. Cette table est essentielle pour éviter de retraiter les mêmes fichiers. Elle garantit l'idempotence du pipeline, un principe fondamental en data engineering.

file_tracking — Showing 3 rows

Table view

	file_name	file_path	processed_at
1	SalesTest1(private).csv	abfss://3b672d63-a2ee-4726-92cb-a96df175d490@onelake.dfs....	2026-02-26T09:57:45.229Z
2	SalesTest2private).csv	abfss://3b672d63-a2ee-4726-92cb-a96df175d490@onelake.dfs....	2026-02-26T09:57:45.229Z
3	sales_data_1.csv	abfss://3b672d63-a2ee-4726-92cb-a96df175d490@onelake.dfs....	2026-02-26T09:57:45.229Z

- **Détection des nouveaux fichiers :** Une fois les données insérées dans la couche Bronze par l'activité Copy Data, Le notebook liste les fichiers du dossier *Bronze* puis compare les chemins avec ceux déjà présents dans file_tracking afin de ne charger que les nouveaux fichiers et ainsi permettre un traitement incrémental.

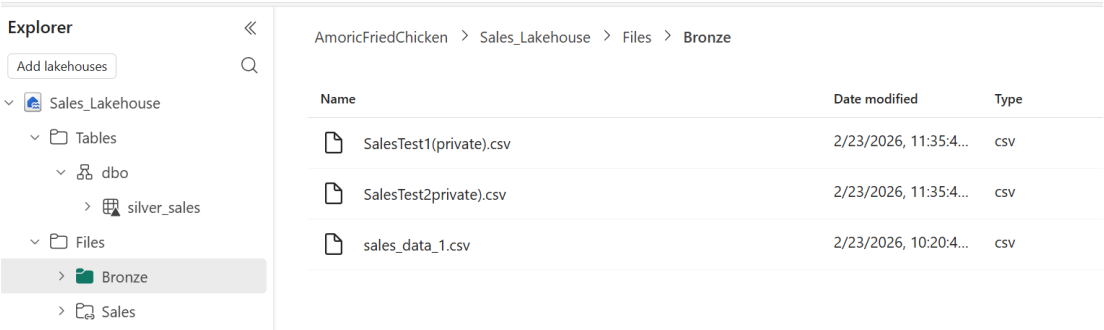

- **Chargement et nettoyage des données :** Les fichiers csv sont ensuite lus avec schéma inféré puis un nettoyage est appliqué. Par exemple trim supprime les espaces parasites visibles dans les données (ex : "Brazil|"), le typage garantit la cohérence pour les calculs et la BI et la suppression des doublons évite les erreurs d'analyse.
- **Insertion dans la table Silver :** Les données nettoyées sont insérées dans la table Delta silver_sales. Le format Delta permet l'ACID, le time travel et une performance optimale. La table Silver devient la source fiable pour les dashboards.

silver_sales — Showing 1000 rows

Table view

	username	sale_date	country	product	quantity	unit_price	total_amount
1	user66	2025-07-25	Brazil	Grilled Tenders	13	4.71	61.23
2	user71	2025-09-26	Brazil	Chicken Nuggets	18	2.64	47.52
3	user309	2025-01-07	UK	Fried Wings	14	14.35	200.9
4	user375	2025-02-11	USA	Fried Wings	3	14.5	43.5
5	user63	2025-05-08	India	Spicy Strips	8	4.41	35.28
6	user468	2025-03-01	Brazil	Chicken Nuggets	3	12.1	36.3
7	user881	2025-02-26	India	Grilled Tenders	3	6.65	19.95
8	user873	2025-01-20	USA	Fried Wings	9	3.51	31.59
9	user956	2025-02-27	India	Spicy Strips	18	11.49	206.82
10	user692	2025-03-07	India	Grilled Tenders	1	4.57	4.57
11	user283	2025-07-28	Germany	Chicken Nuggets	19	3.3	62.7
12	user247	2025-01-05	USA	Chicken Nuggets	17	7.74	131.58
13	user176	2025-05-21	Brazil	Spicy Strips	19	2.61	49.59
14	user178	2025-08-20	France	Grilled Tenders	4	13.99	55.96
15	user4	2025-01-24	France	Spicy Strips	7	3.61	25.27

- **Mise à jour de la table de tracking :** Chaque fichier traité avec succès est ajouté à la table file_tracking, ce qui facilite la supervision et permet un audit complet des traitements

A la fin du processus :

- Les fichiers de ventes sont correctement copiés en Bronze.
- La table de tracking assure une traçabilité complète
- La table Silver contient des données propres, typées et prêtes pour l'analyse.
- Les données sont prêtes pour être utilisées dans Power BI ou d'autres analyses.

B- TRAITEMENT DES CAMPAGNES

B.1. Récupération des Feedbacks

Dans le cadre des campagnes marketing, il est essentiel de collecter, centraliser et analyser les feedbacks des utilisateurs pour :

- Mesurer la satisfaction client.
- Identifier les points forts et axes d'amélioration des campagnes.
- Alimenter un pipeline d'analyse afin de générer des insights actionnables.

L'API a été conçue pour répondre à ces besoins tout en assurant simplicité, fiabilité et évolutivité.

B.1.1 URL de l'API

https://apiamoricfried-gvfzfwb6e2ewa6fr.swedencentral-01.azurewebsites.net/api/getfeedback

B.1.2 Développement et composants de l'API

Flask est utilisé pour structurer la logique de l'API. Il permet de gérer les routes HTTP (GET et POST) de manière intuitive.

Pydantic pour la validation permet de détecter et rejeter les données non conformes et fournir des messages d'erreur clairs aux systèmes consommateurs.

Architecture REST : L'API expose deux opérations :

- **POST** : L'API accepte soit un objet unique, soit une liste de feedbacks. La possibilité d'envoyer des lots optimise le débit lors de campagnes avec de nombreux retours.
- **GET** : L'API renvoie tous les feedbacks collectés

Azure Functions a été utilisé pour déployer l'API en tant que fonction serverless. Ce choix permet une scalabilité automatique des serveurs. La plateforme s'adapte instantanément aux pics de charge, notamment lors de campagnes marketing à forte audience, ce qui réduit la maintenance manuelle et la gestion de serveurs classiques. Lorsqu'un grand nombre de requêtes POST arrivent simultanément, Azure Functions crée automatiquement de nouvelles instances de la fonction et chaque instance traite une partie des requêtes. La montée en charge est quasi instantanée, sans intervention humaine. Une fois le pic passé, les instances inutiles sont supprimées pour réduire les coûts.

Azure Blob Storage: Les feedbacks sont stockés dans un container Azure Blob, sous forme d'un fichier JSON unique, ce qui facilite la lecture, l'export et la traçabilité. L'API ajoute chaque nouveau feedback à la suite du fichier JSON existant offrant une historisation complète. Blob Storage supporte des milliers d'écritures simultanées ainsi, même si une campagne génère des dizaines de milliers de feedbacks, le stockage ne devient jamais un point de saturation.

Une Évolution future prévue est la possibilité de partitionner par date ou par campagne.

En conclusion, l'API a été conçue pour s'intégrer parfaitement avec le pipeline Fabric. Les feedbacks sont collectés tels quels, sans transformation. Le pipeline Bronze → Silver se charge ensuite de l'enrichissement. Cette séparation des rôles garantit ainsi une simplicité maximale côté API et une qualité de données maîtrisée.

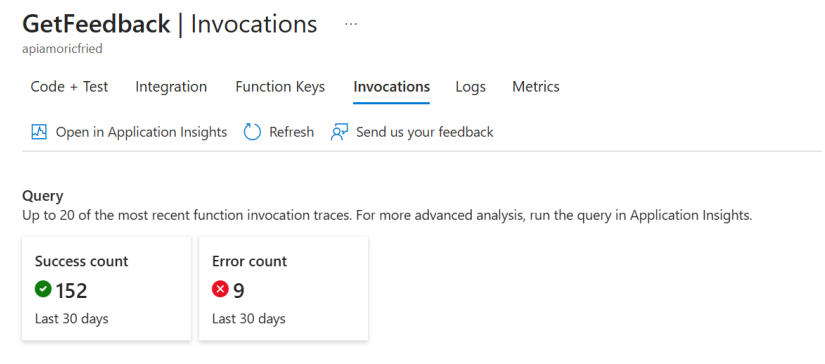

B.2 Traitement et enrichissement

B.2.1. Objectif du pipeline

Le pipeline a pour but de collecter, normaliser, analyser et stocker des feedbacks multilingues provenant de notre API afin de produire une table Silver enrichie par l'IA. Dans Microsoft Fabric, le pipeline suit une architecture en trois couches (Bronze → Silver → IA enrichie), inspirée du modèle *Médaillon Architecture*. Cette structure permet de séparer clairement les données brutes, normalisées et enrichies et de rendre le pipeline robuste, ré exécutable et industrialisable.

B.2.2. Sécurisation des accès et configuration Azure

Les clés sensibles (API OpenAI, endpoint, URL de l'API feedback) sont stockées dans Azure Key Vault. Cela permet :

- D'éviter toute fuite accidentelle dans un repository
- De centraliser la gestion des secrets
- De bénéficier du contrôle d'accès RBAC Azure, ici *Key Vault Secrets User*
- De pouvoir révoquer ou renouveler les secrets sans modifier le code

Les notebooks dans Fabric récupèrent ainsi dynamiquement les secrets via l'identité managée de l'espace de travail. Les secrets actuellement utilisés dans le Key Vault sont:

- AZURE-OPENAI-API-KEY
- AZURE-OPENAI-ENDPOINT
- FEEDBACK-URL

Le notebook utilise désormais *mssparkutils.credentials.getSecret()* pour récupérer les secrets. L'usage de l'identité managée du Workspace Fabric garantit également une authentification sans mot de passe et une conformité aux bonnes pratiques Azure

B.2.3. Ingestion Bronze : données brutes et déduplication

La table Bronze stocke les feedbacks exactement tels que l'API les renvoie, sans transformation. Cela garantit une traçabilité totale, éviter toute perte d'information et rejouer le pipeline si nécessaire. Cependant, chaque feedback reçoit un identifiant unique basé sur un hash SHA-256 construit à partir de : *username, campaign_id* et *Comment*

Ce choix est pertinent car SHA-256 est déterministe : même entrée → même sortie. Ainsi il garantit l'unicité quasi absolue et permet de détecter les doublons même si l'API renvoie l'historique complet.

Avant d'insérer dans Bronze, les identifiants existants sont comparés aux nouveaux et seuls les feedbacks jamais vus sont insérés. Ce mécanisme évite ainsi les réinsertions inutiles et les surcoûts de traitement.

B.2.4. Normalisation Silver : qualité et cohérence

Les fonctions de normalisation *normalize_date, normalize_campaign_id* et *normalize_comment* permettent d'harmoniser les dates, de standardiser les identifiants de campagne, nettoyer les commentaires et éliminer les valeurs incohérentes. Les feedbacks invalides sont exclus de Silver, ce qui garantit une table fiable et une meilleure qualité pour les modèles IA.

B.2.5. Analyse IA : robustesse et enrichissement

L'objectif de cette étape est de transformer un commentaire brut de feedback marketing en données structurées et enrichies. Les tâches effectuées sont :

- Traduction du commentaire an Anglais
- Note globale : De 0 à 5

- Analyse de sentiment : "Positive, Negative, Neutral"
- Classification selon la dimension marketing : "Creativity, Clarity, Engagement, Global Strategy”
- Extraction d’adjectifs clés : Par exemple « satisfait »

Le modèle Azure OpenAI GPT-4.1 est utilisé pour analyser les commentaires multilingues. Ce choix est justifié par sa capacité à comprendre et traduire plusieurs langues et sa précision en analyse de sentiment. Ce modèle a été évalué selon la cohérence des sentiments détectés, la qualité des traductions et la reproductibilité des résultats.

Pour vérifier la fiabilité du modèle, nous avons procédé à un **test manuel vs IA** sur un échantillon de **70 feedbacks** provenant de campagnes marketing récentes. Chaque champ du modèle a été comparé avec l’annotation humaine et la précision a été calculée comme le pourcentage de correspondances exactes.

Résultats :

Champ	Exactitude
sentiment_label	97 %
Marketing_dimension	98 %
key_adjectives	82 %

Observation :

- Le modèle est très performant pour le sentiment et la dimension marketing.
- Les adjectifs clés présentent plus de variabilité, ce qui est normal vu la nature libre des mots choisis

Conclusion

- Sur 70 feedbacks testés, le modèle a montré une précision globale élevée, suffisante pour un usage opérationnel.
- La traduction anglaise a été correcte dans 100 % des cas et facilite l’analyse multilingue.
- Le pipeline IA est validé pour enrichir automatiquement les nouveaux feedbacks dans la table Silver.

Flux de traitement :

Pour chaque nouveau feedback reçu :

1. ***Récupération des informations brutes***
    - *feedback_id, username, feedback_date, campaign_id, comment.*
2. ***Création du prompt IA***
    - *Le commentaire est envoyé au modèle via Azure OpenAI.*
    - *Le prompt demande explicitement :*
        - *Détecter la langue.*

        - *Traduire le commentaire en anglais*
        - *Effectuer une analyse de sentiment*
        - *Classer la dimension marketing*
        - *Extraire un adjectif clé en anglais décrivant le feedback.*
    - *Le résultat attendu est un **JSON strict** avec ces champs.*
3. ***Récupération et parsing du JSON***
    - *Le JSON renvoyé par le modèle est chargé en dictionnaire Python.*
    - *Les champs sont extraits : english_translation, marketing_dimension, star_rating (score calculé par l'IA), sentiment_label, key_adjectives*
4. ***Construction de la ligne Delta***
    - *Chaque feedback enrichi est stocké dans un dictionnaire avec :*
        - *Les colonnes originales*
        - *Les nouvelles Colonnes enrichies par l'IA*
        - *L'heure du traitement*

B.2.6. Ecriture idempotente via Delta MERGE

Avant insertion dans la table Silver, les résultats IA sont filtrés. On vérifie que sentiment_label est bien dans ["Positive", "Negative", "Neutral"], star_rating est entre 0 et 5 et que la marketing_dimension est parmi les valeurs autorisées

Les lignes validées sont ensuite insérées dans la table Delta Silver via un merge() sur feedback_id. Ce choix garantit une insertion uniquement des nouveaux feedbacks et une garantie d'unicité

Chaque ligne dans silver_feedback contient désormais :

Colonne	Description
feedback_id	Identifiant unique du feedback
username	Nom de l'utilisateur
feedback_date	Date du feedback
campaign_id	ID de la campagne marketing
comment	Texte original
english_translation	Commentaire traduit en anglais
marketing_dimension	Dimension marketing analysée
star_rating	Score 0-5 donné par l'IA
sentiment_label	Sentiment détecté
key_adjectives	Mot-clé principal décrivant le feedback
processed_at	Date et heure du traitement

B.2.7. Automatisation

Les feedbacks peuvent arriver à tout moment, en faible ou très forte quantité, selon l'activité marketing. L'API déployée sur Azure Functions est conçue pour absorber ces variations sans intervention humaine car Azure Functions crée automatiquement autant d'instances que nécessaire lorsque le volume augmente.

Contrairement à la collecte, le traitement IA n'a pas besoin d'être continu. Il est volontairement découplé et planifié, ce qui apporte stabilité et maîtrise des coûts. En effet, faire un appel à l'IA pour chaque commentaire individuel augmenterait les dépenses. C'est pourquoi lors des périodes de forte activité marketing, le client peut ajuster facilement la fréquence d'exécution du traitement IA. Le scheduler Fabric permet de passer d'un traitement hebdomadaire à un traitement quotidien, voire plusieurs fois par jour.

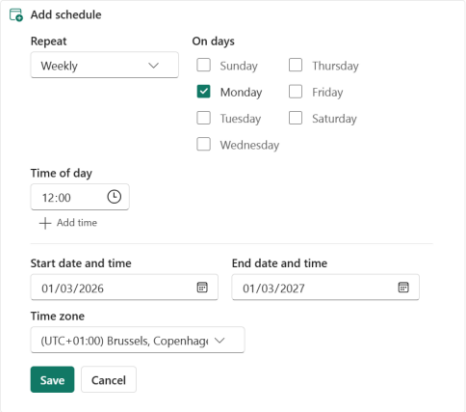

Cette combinaison de collecte continue et traitement planifié est un choix stratégique qui apporte plusieurs bénéfices :

- **Résilience** : l'API absorbe les pics sans risque de saturation.
- M**aîtrise des coûts** : l'IA n'est exécutée que lorsque nécessaire.
- **Flexibilité** : la fréquence peut être ajustée selon les besoins marketing.
- **Simplicité opérationnelle** : les équipes n'ont pas à gérer la montée en charge.
- **Qualité des données** : le traitement batch garantit une normalisation cohérente.

C- BUSINESS ANALYTICS

C.1. Modèle Sémantique

Le modèle repose sur trois tables principales.

Table *Sales :* Cette table contient les données transactionnelles liées aux ventes. Elle constitue une **table de faits**, avec un volume potentiellement élevé et des mesures quantitatives.

Table *Feedback* : Cette table regroupe les retours utilisateurs sur les campagnes marketing. Elle constitue également une **table de faits**, centrée sur la qualité perçue des campagnes.

Table *Calendrier* : Une table de dates a été créée pour structurer les analyses temporelles. Elle contient : *Date, Année* et *Mois*. Cette table constitue une dimension temporelle, indispensable pour les analyses chronologiques. La création de cette table de dates permet :

- D'uniformiser les analyses temporelles entre ventes et feedbacks,
- De faciliter les comparaisons mensuelles, trimestrielles et annuelles,
- D'utiliser les fonctions DAX temporelles (YTD, YOY, MOM),
- D'assurer la cohérence des filtres temporels dans les visuels.

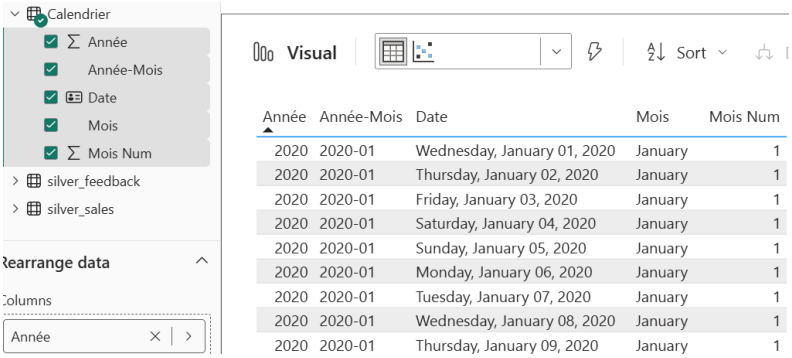

Ainsi, deux relations principales ont été créées entre la table Calendrier et les tables de faits :

3.1. Relation Calendrier → silver_sales

- *Colonne de liaison : Calendrier[Date] → silver_sales[sale_date]*
- *Cardinalité : Many-to-one (:1)**

3.2. Relation Calendrier → silver_feedback

- *Colonne de liaison : Calendrier[Date] → silver_feedback[feedback_date]*
- *Cardinalité : Many-to-one (:1)**

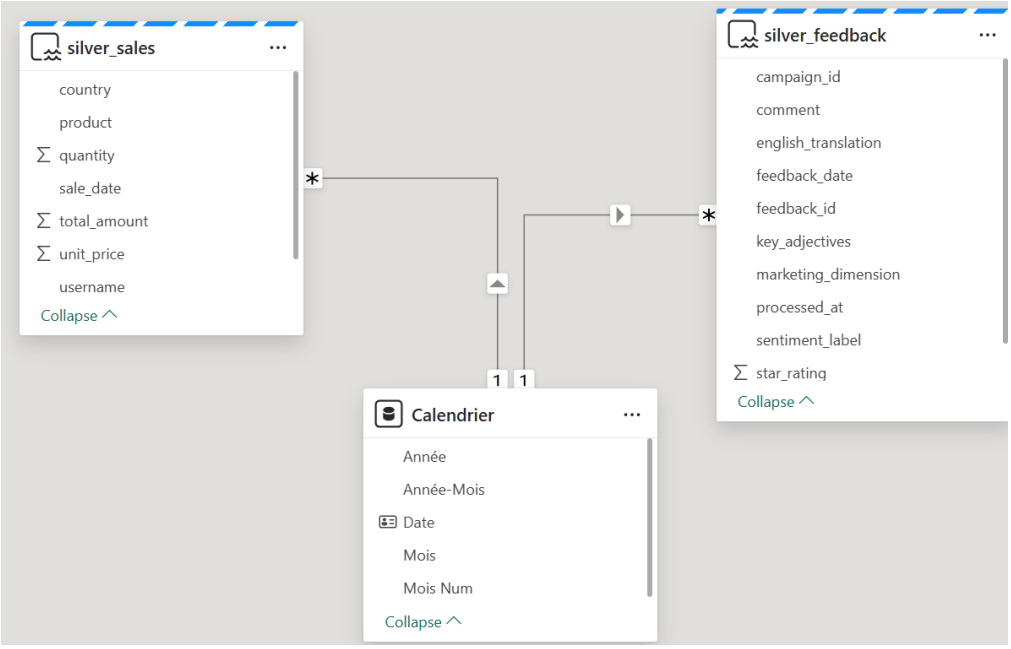

Ces relations respectent les bonnes pratiques d'un **modèle en étoile**, où la table Calendrier joue le rôle de dimension centrale. Les tables *silver_sales* et *silver_feedback* contiennent

plusieurs lignes par date, tandis que la table Calendrier contient une seule ligne par date. La cardinalité *:1 est donc la seule correcte et garantit un comportement analytique fiable.

C.2. Dashboard

Le tableau de bord a été conçu pour fournir une vision intégrée de la performance commerciale, de la satisfaction client et de l'efficacité des campagnes marketing. Il combine des indicateurs financiers, des analyses temporelles, des insights qualitatifs et des répartitions géographiques, permettant une prise de décision éclairée et rapide.

Indicateurs financiers et volumétriques

- **Total Revenue :** Cet indicateur répond à la question : *« Quel est le chiffre d'affaires total généré sur la période sélectionnée ? »* Il permet d'évaluer immédiatement la performance financière globale.
- **Sum of Quantity** Ce KPI répond à : *« Quel volume total de produits a été vendu ? »* Il offre une mesure du niveau d'activité indépendamment des prix.

Analyse par produit

- **Sum of total_amount by Product** Ce graphique répond à : *« Quels produits génèrent le plus de revenus ? » « Quels produits sont les plus performants ou les moins performants ? »* Il permet d'identifier les best-sellers et les produits nécessitant une attention particulière.

Analyse géographique

- **Sum of total_amount by country** Ce visuel répond à : *« Quels pays contribuent le plus au chiffre d'affaires ? » « Quelle est la répartition géographique des ventes ? »* Il met en évidence les marchés stratégiques et les zones à potentiel.

Analyse du sentiment client

- **Count of sentiment_label by sentiment_label** Ce graphique répond à : *« Quel est le sentiment global exprimé par les clients ? » « Quelle proportion de feedbacks est positive, négative ou neutre ? »* Il permet d'évaluer la perception globale des campagnes et des produits.
- **Average / Min / Max star_rating** Cet indicateur répond à : *« Quelle est la note moyenne attribuée par les clients ? » « Quelle est la meilleure et la pire note observée ? »* Il fournit une mesure synthétique de la satisfaction client.
- **Word Cloud – Key Adjectives** Ce nuage de mots répond à : *« Quels adjectifs reviennent le plus souvent dans les commentaires clients ? »* Il met en lumière les thèmes dominants et les perceptions clés.

Analyse temporelle

- **Sum of quantity by Année-Mois** Ce graphique répond à : *« Comment évoluent les ventes au fil des mois ? » « Observe-t-on une saisonnalité, une croissance ou une baisse ? »* Il permet de suivre la dynamique commerciale dans le temps.

Analyse des dimensions marketing

- **Count of marketing_dimension by marketing_dimension** Ce visuel répond à : *« Quels aspects marketing sont le plus souvent mentionnés dans les feedbacks ? »* Il permet d'identifier les dimensions les plus visibles ou les plus sensibles pour les clients.

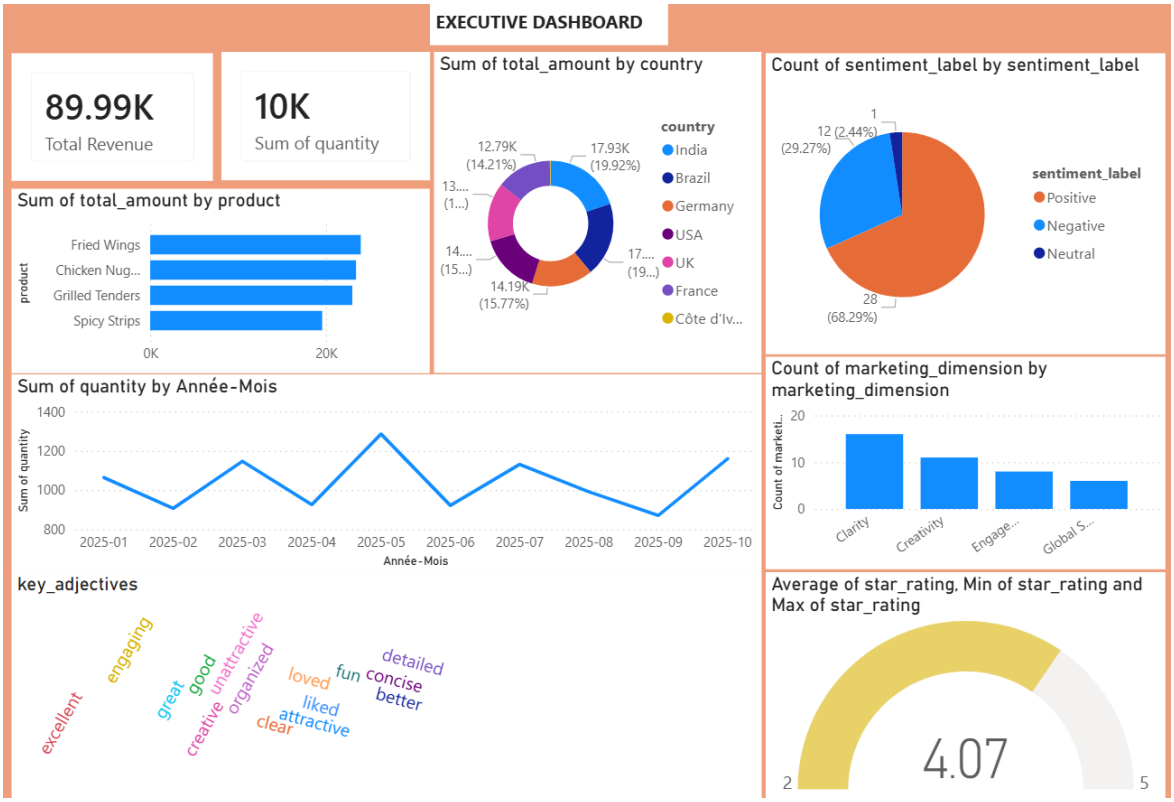

C.3. Rôle des filtres dans l'analyse

3.1. Filtre Année

Ce filtre permet de répondre à :

- *« Comment les ventes et les feedbacks évoluent-ils d'une année à l'autre ? »*
- *« Quelle année a été la plus performante ? »*
- *« Le sentiment client s'améliore-t-il ou se dégrade-t-il selon les années ? »*

Il synchronise l'ensemble du tableau de bord pour offrir une analyse temporelle cohérente.

3.2. Filtre Campaign ID

Ce filtre permet de répondre à :

- *« Quelle campagne marketing a généré le plus de ventes ? »*
- *« Quelle campagne a reçu les meilleurs ou les pires feedbacks ? »*
- *« Comment les performances varient-elles d'une campagne à l'autre ? »*

Il permet une analyse granulaire, centrée sur l'efficacité des actions marketing.

Conclusion

Ce projet a permis de mettre en place une chaîne de traitement complète et fiable pour centraliser, nettoyer et valoriser les données de ventes (*Sales*) et de retours clients (*Feedback*). En s'appuyant sur l'écosystème Azure, et plus particulièrement sur Microsoft Fabric et Power BI, nous avons construit une solution cohérente, moderne et parfaitement adaptée aux besoins d'analyse de l'entreprise.

L'utilisation de Microsoft Fabric a offert un environnement unifié pour gérer l'ingestion, le stockage et la transformation des données. La structuration en couches Bronze et Silver a permis de séparer clairement les données brutes des données prêtes à l'analyse, tout en garantissant une meilleure qualité et une meilleure traçabilité. La mise en place d'une table de suivi des fichiers traités a renforcé la fiabilité du processus en évitant les doublons et en assurant un historique complet des traitements.

Power BI s'est naturellement intégré à cette architecture en permettant de transformer les données Silver en tableaux de bord dynamiques et accessibles. Cette continuité entre Fabric et Power BI a facilité la création d'indicateurs pertinents, utiles pour le pilotage des ventes et l'analyse des retours clients.

Au final, ce projet démontre qu'une architecture bien pensée, basée sur des outils intégrés et automatisés, permet de transformer des fichiers CSV dispersés en une véritable source d'information stratégique. La solution mise en place est évolutive, robuste et prête à accueillir de nouveaux besoins, qu'il s'agisse d'analyses plus avancées, de modèles prédictifs ou de nouvelles sources de données.